Makine Öğrenmesi Yöntemleriyle Kredi Onay Tahmini

Sefer Ağca,Bilgisayar Mühendisliği, Fen Bilimleri Enstitüsü, Gazi Üniversitesi, Ankara, Türkiye

....@gazi.edu.tr

Yavuz Selim Kaya,Bilgisayar Mühendisliği, Fen Bilimleri Enstitüsü, Gazi Üniversitesi, Ankara, Türkiye

yselim.kaya@gazi.edu.tr

ÖZET

Finansal kuruluşlarda kredi başvurularının doğru ve hızlı biçimde değerlendirilmesi, hem kurumsal risk yönetimi hem de müşteri memnuniyeti açısından kritik bir öneme sahiptir. Bu çalışmada, UCI Makine Öğrenmesi Deposu'ndan elde edilen Credit Approval veri seti üzerinde makine öğrenmesi algoritmaları karşılaştırmalı olarak uygulanmış ve Stacking tabanlı özgün bir hibrit model önerilmiştir. Veri seti 690 gözlem ve gizlilik amacıyla anonim tutulmuş 15 özellikten oluşmaktadır. Ön işleme aşamasında eksik değerler istatistiksel yöntemlerle tamamlanmış, kategorik değişkenler sayısallaştırılmış ve tüm özellikler StandardScaler ile standartlaştırılmıştır. Eğitim setindeki sınıf dengesizliği SMOTE yöntemiyle giderilerek her iki sınıf 315 örnekle eşit temsile kavuşturulmuştur. Karar Ağacı, K-En Yakın Komşu, Rastgele Orman, XGBoost, LightGBM ve Yapay Sinir Ağları olmak üzere altı farklı algoritma eğitilmiş; taban öğrenici olarak Rastgele Orman, K-En Yakın Komşu ve Naif Bayes, meta-öğrenici olarak ise Lojistik Regresyon kullanan Stacking hibrit modeli geliştirilmiştir. Elde edilen bulgular, GridSearchCV ile optimize edilen Rastgele Orman modelinin %89,68 doğrulukla en yüksek noktasal başarıya ulaştığını; Stacking hibrit modelinin ise 0,8696 doğruluk ve 0,9034 ROC-AUC skoru ile en dengeli genel performansı sergilediğini ortaya koymaktadır. On katlı çapraz doğrulamada elde edilen 0,8937 ± 0,0302 ortalama doğruluk, modelin kararlılığını kanıtlamaktadır. Finansal risk yönetimi için optimal karar eşiği 0,4257 olarak belirlenmiş; SHAP analizi ile model kararları şeffaf hale getirilmiştir.

Anahtar Kelimeler: Kredi Onay Tahmini, Makine Öğrenmesi, Stacking Hibrit Model, SMOTE, Açıklanabilir Yapay Zeka, ROC-AUC

1. Giriş

Finansal sektörde kredi değerlendirmesi, bankacılık ve finans kuruluşlarının sürdürülebilir büyüme sağlayabilmesi açısından hayati bir öneme sahiptir. Bir kredi başvurusunun olumlu ya da olumsuz sonuçlanmasına ilişkin karar, yalnızca kurumun kısa vadeli gelir tablosunu değil, aynı zamanda uzun dönemli risk yönetimi stratejisini ve itibarını da doğrudan şekillendirmektedir. Ne var ki geleneksel değerlendirme süreçleri, deneyimli

analistlerin sezgisel yargılarına ve katı kural tablolarına dayalı yapısıyla, günümüzün hızla artan başvuru hacmine ve karmaşıklaşan müşteri profillerine yeterince adapte olamamaktadır. Bu durum, hatalı onay ya da red kararlarının hem kurumsal kayıplara hem de müşteri memnuniyetsizliğine yol açtığı senaryoları kaçınılmaz kılmaktadır.

Söz konusu kısıtlamaların aşılmasında makine öğrenmesi yaklaşımları son derece umut verici bir alternatif sunmaktadır. Tarihsel veri örüntülerinden sistematik biçimde çıkarım yapabilen algoritmalar, çok sayıda değişkeni eş zamanlı olarak işleyerek insan analistlerin fark edemeyeceği gizli ilişkileri modelleyebilmektedir. Bununla birlikte, literatürde sıkça gözlemlendiği üzere hiçbir algoritma her veri yapısı ve problem türü için evrensel bir üstünlük sergileyememektedir. Bu gerçeklik, birden fazla modelin birbirini tamamlayacak biçimde bir araya getirildiği topluluk öğrenme yaklaşımlarını özellikle cazip kılmaktadır.

Bu motivasyondan hareketle çalışmada, UCI Makine Öğrenmesi Deposu'ndan temin edilen Credit Approval veri seti kullanılmıştır. Gerçek dünya kredi başvurularını yansıtan bu veri seti, gizlilik kaygısıyla anonim tutulmuş 15 özellik ve 690 gözlemden oluşmakta; hem sayısal hem de kategorik değişkenler içermektedir. Ön işleme aşamasında eksik gözlemler istatistiksel yöntemlerle tamamlanmış, kategorik değişkenler sayısal gösterimlere dönüştürülmüş ve tüm özellikler StandardScaler ile normalize edilmiştir. Eğitim verisindeki sınıf dengesizliği ise azınlık sınıfına yönelik sentetik örnekler üreten SMOTE algoritması aracılığıyla giderilmiştir.

Araştırmanın temel hedefi, Karar Ağacı, K-En Yakın Komşu, Rastgele Orman, XGBoost, LightGBM ve Yapay Sinir Ağları olmak üzere altı farklı algoritmayı aynı deneysel koşullar altında karşılaştırmalı olarak incelemek ve bu modellerin tamamlayıcı güçlerini harmanlayan Stacking tabanlı özgün bir hibrit mimari ortaya koymaktır. Geliştirilen hibrit yapıda Rastgele Orman, K-En Yakın Komşu ve Naif Bayes taban öğrenici olarak konumlandırılmış; bu modellerin ürettiği olasılık çıktıları üzerinden nihai kararı veren Lojistik Regresyon ise meta-öğrenici rolünü üstlenmiştir. Modelin kararlılığı ve genelleme gücü 10 katlı çapraz doğrulama ile sınanmış; finansal kayıpları minimize edecek optimal karar eşiği Precision-Recall eğrisi üzerinden F1 skoru maksimizasyonuyla belirlenmiştir. Çalışma ayrıca, modelin kara kutu niteliğini aşmak ve karar mekanizmalarını şeffaf biçimde ortaya koymak amacıyla SHAP tabanlı açıklanabilir yapay zeka analizini de kapsamaktadır.

2. Materyal ve Yöntem

Bu çalışmada izlenen araştırma süreci; veri temini, ön işleme, model tasarımı ve performans değerlendirmesi olmak üzere birbirini mantıksal olarak izleyen dört ana aşamadan oluşmaktadır. Her aşamada uygulanan yöntemler, tekrarlanabilirlik ve bilimsel şeffaflık ilkeleri gözetilerek aşağıda ayrıntılı biçimde aktarılmaktadır.

Veri toplama sürecinde UCI Makine Öğrenmesi Deposu'nda kamuya açık olarak sunulan Credit Approval veri setinden yararlanılmıştır. Bu veri seti, gerçek bir finansal kuruma ait kredi başvuru kayıtlarından türetilmiş olup başvuru sahiplerine ilişkin kişisel ve finansal bilgileri kapsamaktadır. Gizlilik gerekçesiyle tüm özellik adları anonim bırakılmış ve A1'den A15'e kadar etiketlenmiştir. Veri seti 690 gözlem ile 15 bağımsız değişken ve bir hedef değişkenden oluşmakta; sütunların dördü sürekli sayısal, ikisi tam sayı ve onu kategorik tipte veri içermektedir. Hedef değişken, başvurunun onaylandığını ifade eden artı ve reddedildiğini ifade eden eksi olmak üzere iki sınıftan meydana gelmekte olup veri setinin yaklaşık yüzde elli beşi red, kalan kısmı ise onay olarak etiketlenmiştir.

Veri ön işleme aşamasının ilk adımında eksik gözlemler ele alınmıştır. A1, A2, A4, A5, A6, A7 ve A14 sütunlarında soru işareti sembolüyle kodlanmış toplam 67 eksik değer tespit edilmiş ve bu değerler önce Python'ın NumPy kütüphanesi aracılığıyla NaN formatına dönüştürülmüştür. Ardından sayısal sütunlardaki eksiklikler ilgili sütunun aritmetik ortalamasıyla, kategorik sütunlardakiler ise mod değeriyle doldurulmuştur. Bu yaklaşım, veri kaybını tamamen önlerken dağılım üzerindeki bozucu etkiyi en aza indirgemektedir. İkinci adımda kategorik değişkenler scikit-learn kütüphanesinin LabelEncoder sınıfı kullanılarak tam sayısal temsillere dönüştürülmüştür. Üçüncü adımda ise tüm sayısal özellikler, farklı ölçek aralıklarının model performansını olumsuz etkilemesini önlemek amacıyla StandardScaler ile ortalaması sıfır ve standart sapması bir olacak biçimde standartlaştırılmıştır. Son olarak veri seti, sınıf oranları korunacak şekilde yüzde seksen eğitim ve yüzde yirmi test olarak ayrılmıştır.

Eğitim setindeki sınıf dengesizliği sorunu, modelin çoğunluk sınıfına yönelik önyargılı öğrenmesini engellemek amacıyla SMOTE yöntemiyle giderilmiştir. Dengesiz veri setlerinde eğitilen modeller, azınlık sınıfını neredeyse hiç doğru tahmin edemese dahi yüksek doğruluk değeri raporlayabilmektedir; çünkü her örneği çoğunluk sınıfına atamak başlı başına istatistiksel olarak avantajlı bir strateji haline gelmektedir. Bu çalışma özelinde değerlendirildiğinde, modelin tüm başvuruları otomatik olarak reddedilmiş gibi

sınıflandırması durumunda bile yüzde elli beşin üzerinde bir doğruluk elde edilebileceği görülmektedir. Oysa kredi onay tahmini bağlamında asıl kritik olan, gerçekten onaylanması gereken başvuruların doğru biçimde tespit edilmesidir; zira bu sınıfın kaçırılması hem haksız red kararlarına hem de kurumun potansiyel müşteri kaybına yol açmaktadır. SMOTE, mevcut azınlık sınıfı örnekleri arasındaki k-en yakın komşuluk ilişkilerinden yararlanarak bu örneklerin özellik uzayındaki ara noktalarına sentetik veri noktaları yerleştirmekte ve böylece sınıf dağılımını yapay kopyalama yapmaksızın dengeli hale getirmektedir. Bu işlem sonucunda eğitim setindeki her iki sınıf da 315 örnekle eşit biçimde temsil edilir hale gelmiş; modelin her iki sınıfa da eşit önem atfederek öğrenmesi sağlanmış ve özellikle onay sınıfına yönelik duyarlılık değerleri belirgin ölçüde iyileştirilmiştir.

Model geliştirme aşamasında hem yorumlanabilirlik hem de tahmin gücü açısından birbirini tamamlayan altı farklı algoritma uygulanmıştır. Bunların yanı sıra bu algoritmalardan üçünün taban öğrenici olarak kullanıldığı ve Lojistik Regresyon'un meta-öğrenici olarak görev yaptığı beş katlı çapraz doğrulama destekli bir Stacking mimarisi tasarlanmıştır. Tüm modeller SMOTE ile dengelenmiş eğitim seti üzerinde eğitilmiş ve bağımsız test seti üzerinde değerlendirilmiştir. Rastgele Orman modeli için GridSearchCV ile hiperparametre optimizasyonu gerçekleştirilmiş; n_estimators, max_depth ve min_samples_split parametreleri üzerinde ızgara araması yapılmıştır. Model performansları doğruluk ve ROC-AUC metrikleri ile ölçülmüş, Stacking modelinin genelleme kapasitesi ayrıca 10 katlı çapraz doğrulama ile doğrulanmıştır. Çalışmanın son aşamasında ise Precision-Recall eğrisi üzerinden F1 skoru maksimizasyonuyla optimal karar eşiği belirlenmiş ve SHAP TreeExplainer yöntemiyle özellik önem analizi gerçekleştirilmiştir.

2.1.Veri Seti

Bu çalışmada kullanılan Credit Approval veri seti, UCI Makine Öğrenmesi Deposu tarafından kamuya açık olarak sunulmakta olup gerçek bir finansal kuruma ait kredi başvuru süreçlerinden elde edilmiştir. Başvuru sahiplerine ilişkin kişisel ve finansal nitelikteki bilgileri barındıran bu veri seti, gizlilik kaygılarıyla tüm özellik adları anonim tutulmuş ve A1'den A15'e kadar sistematik biçimde etiketlenmiştir. Veri seti toplamda 690 gözlem satırı ve hedef değişken dahil 16 sütundan meydana gelmektedir. Değişken tipleri incelendiğinde dört sütunun sürekli sayısal, iki sütunun tam sayı ve on sütunun ise kategorik nitelik taşıdığı görülmektedir.

Hedef değişken, kredi başvurusunun onaylandığını temsil eden artı ve reddedildiğini temsil eden eksi sınıflarından oluşan ikili bir etiket yapısına sahiptir. Sınıf dağılımı incelendiğinde veri setinin yaklaşık yüzde elli beşinin red, kalan yüzde kırk dördünün ise onay olarak etiketlendiği görülmekte; bu

durum hafif düzeyde bir sınıf dengesizliğine işaret etmektedir.

Veri setinin kalite analizi kapsamında A1, A2, A4, A5, A6, A7 ve A14 sütunlarında soru işareti sembolüyle kodlanmış toplam 67 eksik gözlem tespit edilmiştir. Bu eksik değerler, Python'ın pandas ve NumPy kütüphaneleri aracılığıyla işlenmiş; sayısal sütunlardaki boşluklar ilgili sütunun aritmetik ortalamasıyla, kategorik sütunlardakiler ise en sık gözlemlenen değer olan mod ile doldurulmuştur. Söz konusu yaklaşım, veri kaybını tamamen engellerken merkezi eğilim üzerindeki bozucu etkiyi de minimum düzeyde tutmaktadır. Eksik veri işleminin ardından kategorik değişkenler scikit-learn kütüphanesinin LabelEncoder sınıfı ile sayısal gösterimlere dönüştürülmüş; tüm sayısal özellikler ise farklı ölçek aralıklarının algoritmaların mesafe ve ağırlık hesaplamalarını çarpıtmasını önlemek amacıyla StandardScaler ile ortalaması sıfır ve standart sapması bir olacak biçimde standartlaştırılmıştır. Son aşamada veri seti, sınıf oranları korunarak yüzde seksen eğitim ve yüzde yirmi test olmak üzere iki alt kümeye ayrılmış; bu sayede hem model eğitiminde hem de performans değerlendirmesinde temsil dengesi sağlanmıştır.

2.2. Kullanılan Makine Öğrenmesi Algoritmaları

Bu çalışmada kredi onay tahminini gerçekleştirmek amacıyla birbirinden farklı öğrenme paradigmalarını temsil eden altı temel algoritma uygulanmış ve bu algoritmaların belirli bir kombinasyonundan oluşan Stacking tabanlı hibrit bir model geliştirilmiştir. Algoritma seçiminde hem yorumlanabilirlik hem de tahmin gücü dengesinin gözetilmesi, farklı yapıdaki modellerin aynı deneysel koşullar altında adil biçimde karşılaştırılmasına imkân tanımaktadır.

Karar Ağacı, veriyi özellik değerlerine göre özyinelemeli olarak bölen ve her düğümde Gini safsızlığı kriterini kullanan kural tabanlı bir sınıflandırıcıdır. Yapısının doğrudan görselleştirilebilir olması nedeniyle model kararlarının yorumlanması açısından güçlü bir referans noktası oluşturmaktadır. Ancak eğitim verisine aşırı uyum gösterme eğilimi, tek başına kullanımında genelleme kapasitesini kısıtlayabilmektedir.

K-En Yakın Komşu, yeni bir gözlemi özellik uzayındaki en yakın k komşusunun çoğunluk sınıfına atayan örnek tabanlı bir öğrenme algoritmasıdır. Herhangi bir model parametresi öğrenmeksizin doğrudan eğitim verisini referans alması nedeniyle tembel öğrenici olarak da nitelendirilmektedir. Bu çalışmada k değeri beş olarak belirlenmiş olup algoritmanın mesafeye duyarlı yapısı,

StandardScaler ile gerçekleştirilen ölçeklendirme adımını özellikle kritik kılmaktadır.

Rastgele Orman, bootstrap örneklemesiyle oluşturulan çok sayıda karar ağacının bağımsız olarak eğitildiği ve tahminlerin çoğunluk oylamasıyla birleştirildiği bir topluluk öğrenme yöntemidir. Her ağacın rastgele seçilmiş bir özellik alt kümesi üzerinde büyütülmesi, bireysel ağaçlar arasındaki korelasyonu azaltarak modelin varyansını düşürmekte ve genelleme gücünü artırmaktadır. Çalışmada yüz ağaçla yapılandırılan bu model, aynı zamanda GridSearchCV ile hiperparametre optimizasyonuna da tabi tutulmuştur.

XGBoost, gradyan artırma algoritmasının hız, bellek verimliliği ve düzenleme mekanizmaları açısından optimize edilmiş bir uygulamasıdır. Zayıf öğrenicileri artımlı biçimde birbirine ekleyerek hataları sistematik olarak azaltan bu yöntem, özellikle yapısal tablo verilerinde yüksek tahmin gücüyle öne çıkmaktadır. Aşırı öğrenmeyi kontrol altında tutmak için L1 ve L2 düzenleştirme terimlerini bünyesinde barındırmaktadır.

LightGBM, histogram tabanlı özellik bölme stratejisi ve yaprak odaklı ağaç büyütme yaklaşımıyla XGBoost'a kıyasla belirgin biçimde daha hızlı eğitim süreleri sunan bir gradyan artırma kütüphanesidir. Büyük ölçekli veri setlerinde bellek kullanımını optimize etmesi ve kategorik değişkenleri yerel olarak işleyebilme kapasitesi, bu algoritmayı özellikle karma veri yapılarında cazip kılmaktadır.

Yapay Sinir Ağı, biyolojik sinir sisteminden ilham alarak tasarlanmış ve birbirine bağlı nöron katmanlarından oluşan bir modeldir. Bu çalışmada sırasıyla yüz, elli ve yirmi beş nörondan meydana gelen üç gizli katmanlı bir çok katmanlı algılayıcı mimarisi kullanılmıştır. Aktivasyon fonksiyonu olarak ReLU, optimizasyon algoritması olarak ise Adam tercih edilmiş; model en fazla beş yüz iterasyon ile eğitilmiştir. Öğrenme eğrisi kayıp değerlerinin iterasyon boyunca yakınsadığını göstermekte ve modelin eğitim sürecinin kararlı biçimde ilerlediğine işaret etmektedir.

Stacking tabanlı hibrit model, birden fazla taban öğrenicinin tahmin çıktılarını bir üst düzey meta-öğreniciye girdi olarak sunan ve bu sayede bireysel modellerin zayıflıklarını karşılıklı olarak telafi etmeyi hedefleyen bir topluluk mimarisidir. Bu çalışmada taban öğreniciler olarak Rastgele Orman, K-En Yakın Komşu ve Naif Bayes seçilmiş; bu modellerin beş katlı çapraz doğrulama aracılığıyla ürettiği olasılık tahminleri, nihai kararı veren Lojistik Regresyon meta-modeline aktarılmıştır. Beş katlı çapraz doğrulama kullanımı, taban modellerin eğitim verisi üzerinde aşırı uyum göstermesini önleyerek meta-modele daha güvenilir ve önyargısız girdiler sağlamaktadır. Böylece hiçbir bireysel modelin tek başına ulaşamayacağı bir genelleme kapasitesi hedeflenmektedir.

2.3 Literatür Taraması

Kredi risk değerlendirmesi ve makine öğrenmesi uygulamaları, finans ve bilgisayar bilimleri literatüründe son yıllarda yoğun ilgi gören bir araştırma alanı haline gelmiştir. Bu bölümde çalışmayla doğrudan ilişkili olan ve araştırmanın teorik çerçevesini şekillendiren başlıca çalışmalar ele alınmaktadır.

Tong ve arkadaşları, 2024 yılında kredi kartı onay tahminine yönelik geliştirdikleri çalışmada Lojistik Regresyon, Destek Vektör Makineleri, K-En Yakın Komşu, Karar Ağacı, Rastgele Orman ve Gradyan Artırma modellerini bir araya getiren yapay sinir ağı destekli bir topluluk mimarisi önermiştir. SMOTE ile sınıf dengesizliğini gideren bu çalışma, entegre modelin tek model yaklaşımlarını hassasiyet, duyarlılık, F1-skoru ve AUC metrikleri açısından belirgin biçimde geride bıraktığını ortaya koymuştur. Söz konusu bulgu, mevcut çalışmada Stacking tabanlı hibrit mimarinin tercih edilmesinin temel gerekçelerinden birini oluşturmaktadır.

Shreya ve Pathak, 2025 yılında XGBoost, LightGBM ve Rastgele Orman algoritmalarını SHAP ve LIME açıklanabilirlik teknikleriyle birleştiren şeffaf bir kredi risk değerlendirme sistemi geliştirmiştir. Sınıf dengesizliğinin SMOTE ile giderildiği ve hiperparametre optimizasyonunun GridSearchCV ile gerçekleştirildiği bu çalışma, ROC-AUC, hassasiyet ve F1-skoru metriklerini birlikte kullanarak kapsamlı bir model değerlendirmesi sunmaktadır. Bu yaklaşım, mevcut çalışmada benimsenen çok metrikli değerlendirme stratejisini doğrudan desteklemektedir.

Brown ve Mues, 2012 yılında dengesiz kredi skorlama veri setleri üzerinde çeşitli sınıflandırma algoritmalarını karşılaştırdıkları deneysel çalışmalarında, dengesiz veri yapılarında tek bir doğruluk metriğine dayalı model seçiminin yanıltıcı sonuçlar üretebileceğini kanıtlamıştır. Bu çalışmada ROC-AUC skorunun birincil değerlendirme ölçütü olarak benimsenmesi, söz konusu bulgularla doğrudan örtüşmektedir.

Gramegna ve Giudici, 2021 yılında SHAP ve LIME yöntemlerinin kredi riski bağlamındaki açıklayıcı güçlerini karşılaştırmalı olarak incelemiştir. Çalışma, SHAP'ın hem global hem de yerel düzeyde daha tutarlı ve kararlı açıklamalar ürettiğini ortaya koymuş; bu bulgu mevcut araştırmada SHAP TreeExplainer yönteminin tercih edilmesinin kuramsal dayanağını güçlendirmiştir.

Dumitrescu ve arkadaşları, 2022 yılında doğrusal olmayan karar ağacı etkilerini Lojistik Regresyon ile birleştiren hibrit bir kredi skorlama yaklaşımı

geliştirmiştir. Bu çalışma, tek başına doğrusal modellerin kredi verilerindeki karmaşık ilişkileri yeterince modelleyemediğini ve topluluk yöntemlerinin bu açığı kapattığını deneysel olarak göstermektedir.

Chen ve arkadaşları, 2024 yılında dengesiz kredi skorlama veri setleri için yorumlanabilir makine öğrenmesi yöntemlerini incelemiş; özellik seçimi ve veri dengeleme tekniklerinin model performansı ve açıklanabilirliği üzerindeki etkisini ayrıntılı biçimde analiz etmiştir. Bu çalışma, mevcut araştırmada SMOTE ve SHAP kombinasyonunun seçilmesini destekleyen önemli bir referans işlevi görmektedir.

Li ve arkadaşları, 2024 yılında üç yönlü karar teorisi ile Stacking topluluk yaklaşımını bir araya getiren hibrit bir kredi risk değerlendirme modeli geliştirmiştir. Stacking mimarisinin bireysel modellerin güçlü yönlerini nasıl harmanlayabileceğini somut biçimde ortaya koyan bu çalışma, mevcut araştırmada önerilen hibrit model tasarımıyla yüksek düzeyde örtüşmektedir.

Aruleba ve Sun, 2024 yılında model açıklamasıyla desteklenen topluluk sınıflandırıcıların kredi risk tahminindeki etkinliğini incelemiş; açıklanabilirlik katmanının finansal karar destek sistemlerine olan güveni artırdığını raporlamıştır. Bu bulgu, mevcut çalışmada SHAP analizinin yalnızca teknik bir ek olarak değil, sistemin ayrılmaz bir bileşeni olarak konumlandırılmasının gerekçesini oluşturmaktadır.

Barbaglia ve arkadaşları, 2023 yılında Avrupa kredi piyasası verilerini kullanarak makine öğrenmesi yöntemleriyle kredi temerrüdü tahminini ele almış; gradyan artırmalı modellerin özellikle yapısal tablo verilerinde geleneksel ekonometrik yöntemleri geride bıraktığını göstermiştir. Bu sonuç, mevcut çalışmada XGBoost ve LightGBM'in model portföyüne dahil edilmesinin literatürdeki karşılığını sağlamlaştırmaktadır.

Thomas, Crook ve Edelman, 2017 yılında kredi skorlamasının teorik ve uygulamalı boyutlarını kapsamlı biçimde ele aldıkları kitap çalışmalarında, veri ön işleme, özellik seçimi ve model değerlendirmesine ilişkin temel ilkeleri sistematik olarak ortaya koymuştur. Bu kaynak, mevcut araştırmada izlenen metodolojik çerçevenin oluşturulmasında temel bir başvuru noktası işlevi görmüştür.

3. Bulgular ve Tartışma

Bu bölümde çalışma kapsamında gerçekleştirilen keşifsel veri analizi, model eğitimi ve performans değerlendirmesine ilişkin bulgular sırasıyla sunulmakta; ardından elde edilen sonuçlar literatürle karşılaştırmalı olarak yorumlanmaktadır.

Veri setine ilişkin ilk bulgular, 690 gözlemin 16 değişken üzerinden incelenmesiyle elde edilmiştir. Eksik veri haritası görselleştirildiğinde A1, A2, A4, A5, A6, A7 ve A14 sütunlarında dağınık eksikliklerin bulunduğu ve bu eksikliklerin veri setine düzensiz biçimde yayıldığı gözlemlenmiştir. Toplam 67 eksik gözlem tespit edilmiş olup bu değer tüm veri setinin yaklaşık yüzde dokuzuna karşılık gelmektedir. Hedef değişkenin dağılımı incelendiğinde sınıfların birbirine yakın fakat tam olarak dengeli olmadığı görülmektedir; red sınıfı yüzde 55,51 ile çoğunluğu oluştururken onay sınıfı yüzde 44,49 oranında temsil edilmektedir. Özellikler arası korelasyon matrisi incelendiğinde bazı değişken çiftleri arasında orta düzeyde ilişkiler bulunduğu, bununla birlikte çoklu doğrusallık sorununa yol açacak düzeyde yüksek korelasyonların mevcut olmadığı görülmüştür. Bu durum, seçilen özelliklerin model için bağımsız ve tamamlayıcı bilgi taşıdığına işaret etmektedir.

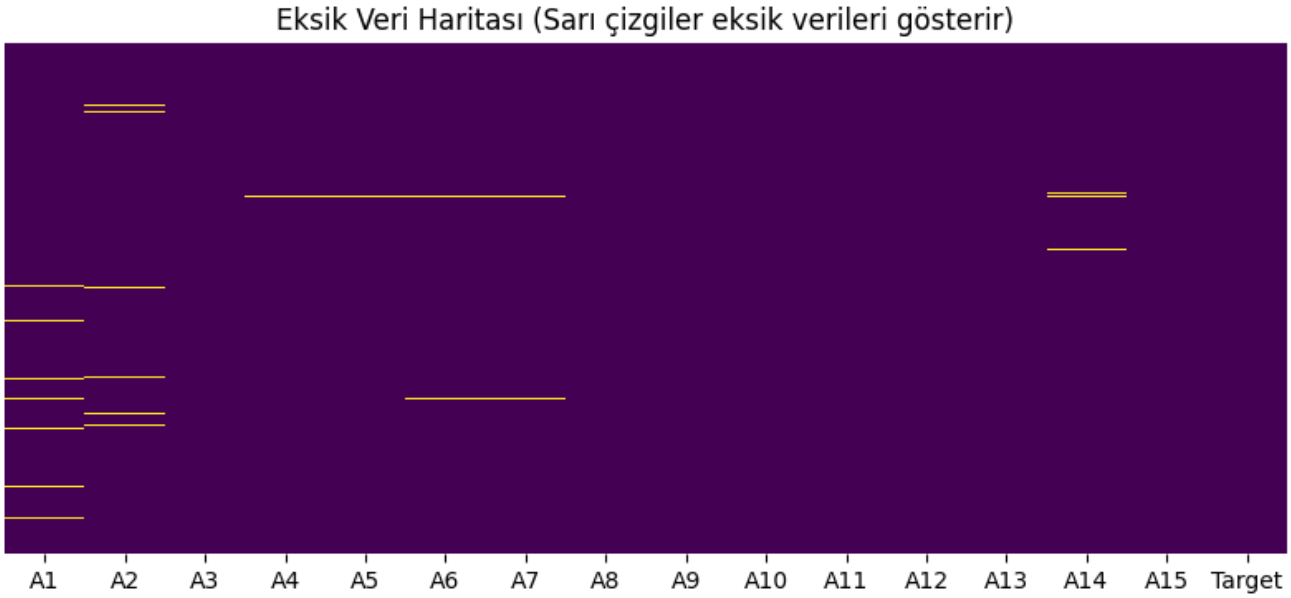

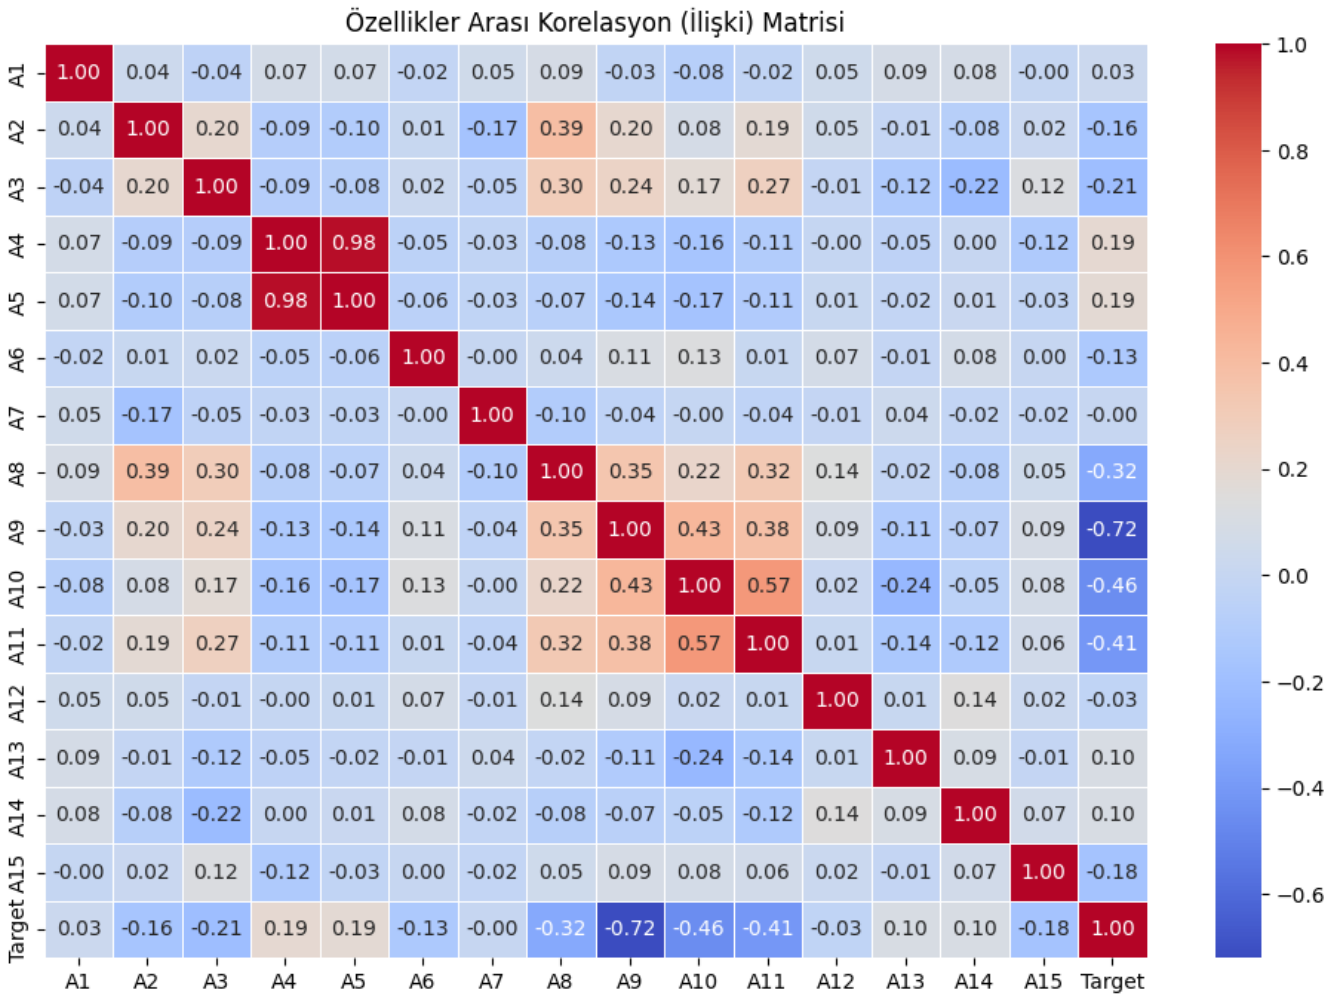

SMOTE uygulaması öncesinde eğitim setindeki onay sınıfı 315, red sınıfı ise 237 örnekten oluşmaktaydı. SMOTE'un sentetik örnekler üretmesiyle birlikte red sınıfı 315 örneğe yükseltilmiş ve her iki sınıf eşit düzeyde temsil edilir hale gelmiştir. SMOTE sonrası dağılım grafiği, iki sınıfın tamamen dengeli bir yapıya kavuştuğunu açıkça ortaya koymaktadır. Bu dengeleme işleminin ardından modellerin azınlık sınıfına yönelik duyarlılık değerlerinde belirgin iyileşmeler gözlemlenmiştir.

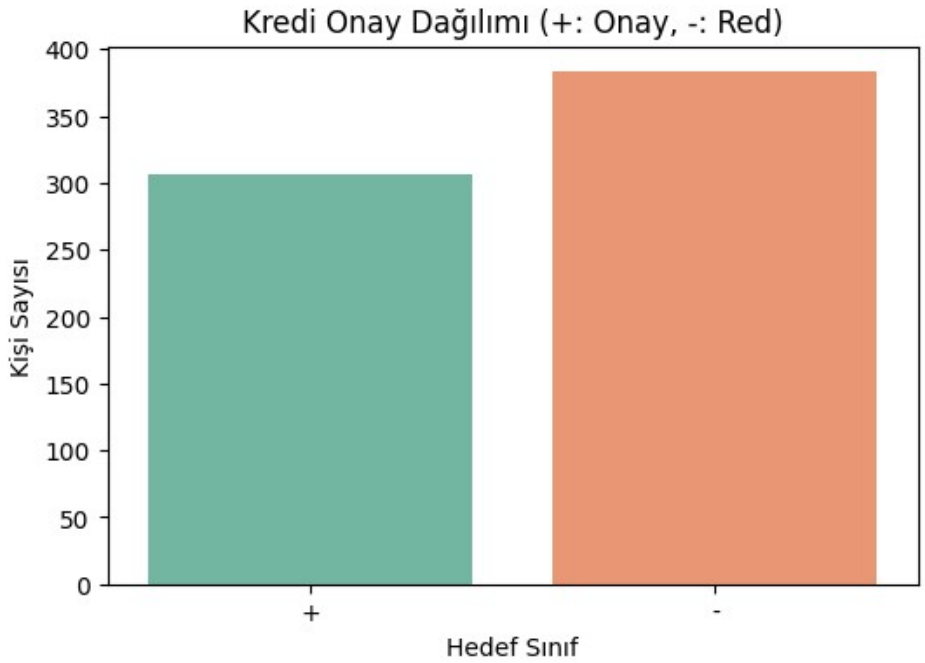

Tüm modeller SMOTE ile dengelenmiş eğitim seti üzerinde eğitilmiş ve bağımsız test seti üzerinde değerlendirilmiştir. Elde edilen doğruluk ve ROC-AUC skorları Tablo 1'de sunulmaktadır.

Model	Doğruluk	ROC-AUC
Karar Ağacı	0,7899	0,7901
K-En Yakın Komşu	0,8333	0,8634
Rastgele Orman	0,8623	0,9155
XGBoost	0,8333	0,9048
LightGBM	0,8406	0,9088
Yapay Sinir Ağı (YSA)	0,7899	0,8481
Hibrit Model (Stacking)	0,8696	0,9034
Optimize Rastgele Orman (GridSearchCV)	0,8968	—

Tablo 1: Elde Edilen Sonuçlar

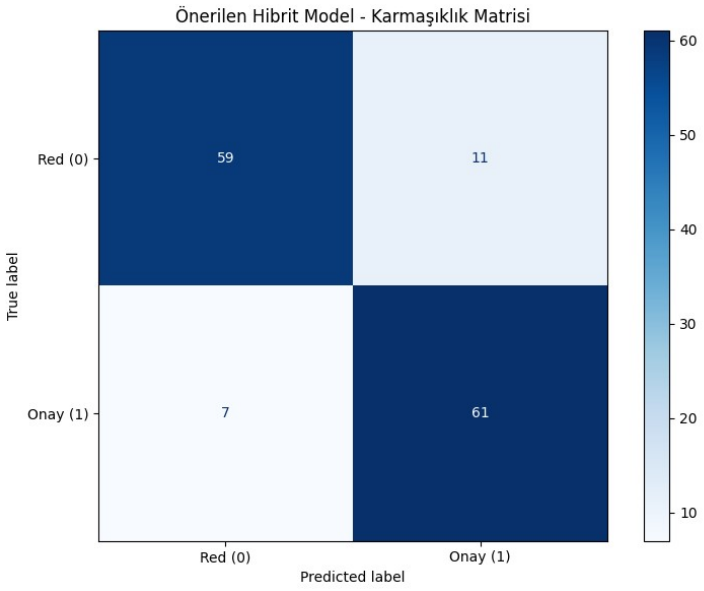

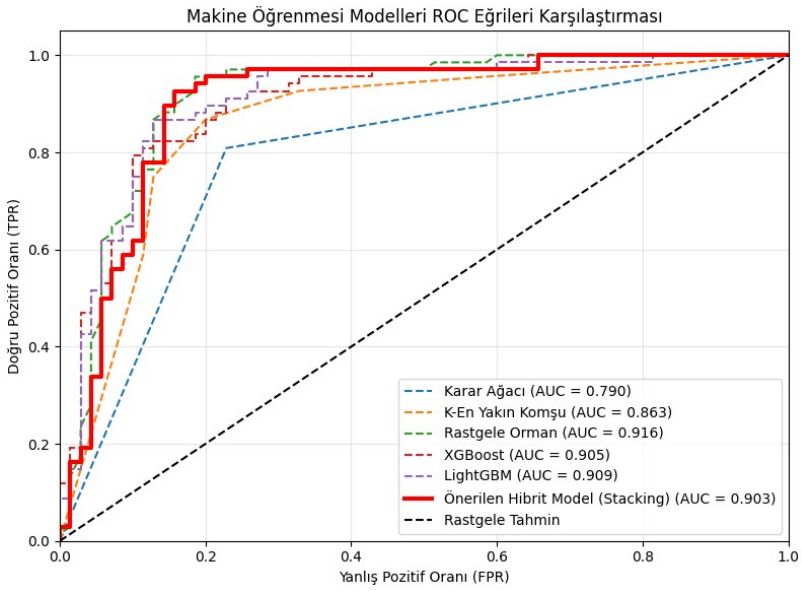

Tablo incelendiğinde en yüksek doğruluk değerinin GridSearchCV ile optimize edilen Rastgele Orman modelinde elde edildiği görülmektedir. ROC-AUC skoru açısından ise optimize edilmemiş Rastgele Orman 0,9155 ile en yüksek değere ulaşmıştır. Önerilen Stacking hibrit modeli 0,8696 doğruluk ve 0,9034 ROC-AUC skoru ile bireysel modellerin büyük çoğunluğunu geride bırakmıştır. Karar Ağacı ve Yapay Sinir Ağı 0,7899 doğruluk ile en düşük performansı sergilerken XGBoost ve LightGBM orta düzey bir performans aralığında kalmıştır.

Stacking hibrit modeline ait karmaşıklık matrisi incelendiğinde modelin gerçek pozitif ve gerçek negatif sınıflandırmalarda genel olarak başarılı olduğu görülmektedir. Yanlış negatif oranının yanlış pozitif oranına kıyasla daha düşük tutulması, finansal risk yönetimi açısından özellikle önem taşımaktadır; zira gerçekte onaylanması gereken bir başvurunun reddedilmesi hem müşteri kaybına hem de gelir kaybına yol açabilmektedir.

Tüm modellerin ROC eğrileri karşılaştırıldığında Rastgele Orman ve Stacking modelinin eğri altında kalan alana göre belirgin biçimde öne çıktığı görülmektedir. Rastgele Orman 0,9155 AUC değeriyle en geniş eğri altı alana sahipken Stacking modeli 0,9034 ile yakın bir performans sergilemiştir. Karar Ağacı ve Yapay Sinir Ağı eğrileri diğer modellere kıyasla köşegene daha yakın bir seyir izlemiş ve bu durum söz konusu modellerin ayrıştırma kapasitesinin görece sınırlı kaldığını ortaya koymuştur.

YSA modelinin eğitim sürecine ilişkin kayıp eğrisi incelendiğinde iterasyon sayısı arttıkça kayıp değerinin düzenli biçimde azaldığı ve modelin

yakınsama davranışı sergilediği gözlemlenmiştir. Beş yüz iterasyon sonunda kayıp değeri kararlı bir platoya ulaşmış olup bu durum modelin eğitim sürecinin başarıyla tamamlandığını ve aşırı salınım olmaksızın öğrenmenin gerçekleştiğini göstermektedir.

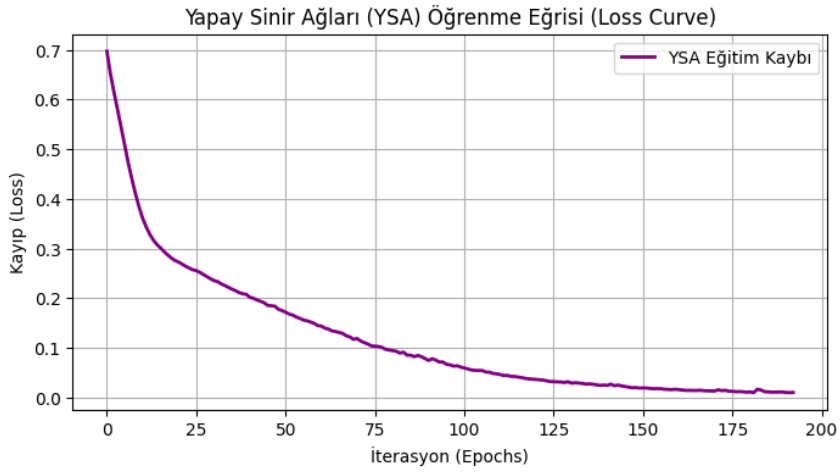

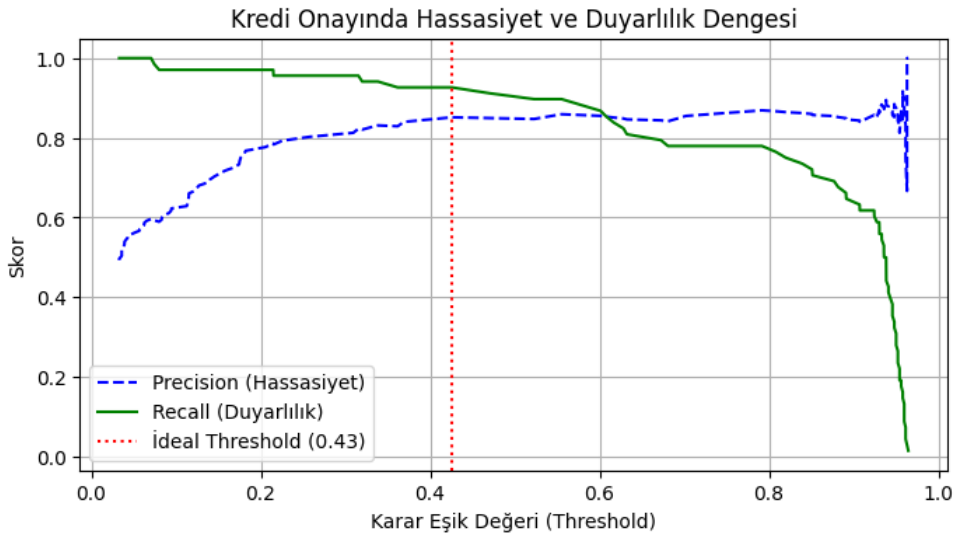

Stacking modeline ait Precision-Recall eğrisi üzerinden F1 skoru maksimizasyonu gerçekleştirilmiş ve finansal risk yönetimi için en uygun karar eşiği 0,4257 olarak belirlenmiştir. Bu değer, standart 0,50 eşiğinin altında kalarak modelin onay sınıfına yönelik duyarlılığının artırılmasını ön planda tuttuğunu ortaya koymaktadır. Söz konusu eşik değeri üzerinden yapılan değerlendirmede hassasiyet ve duyarlılık arasındaki denge, yanlış negatiflerin finansal maliyetini minimize edecek biçimde kurulmuştur.

Rastgele Orman modeline uygulanan GridSearchCV analizi sonucunda en iyi parametre kombinasyonu n_estimators: 100, max_depth: None ve min_samples_split: 2 olarak belirlenmiş; bu parametrelerle elde edilen çapraz doğrulama doğruluğu 0,8968 olarak ölçülmüştür. Parametre ızgarası üç katlı çapraz doğrulama ile değerlendirilmiş ve en iyi kombinasyon bu yapı

üzerinden seçilmiştir.

Stacking hibrit modelinin genelleme kapasitesini sınamak amacıyla uygulanan 10 katlı çapraz doğrulamada her bir katlama için elde edilen doğruluk değerleri sırasıyla 0,9365; 0,9048; 0,9048; 0,8413; 0,9048; 0,8413; 0,9206; 0,8730; 0,9048 ve 0,9048 olarak ölçülmüştür. Ortalama çapraz doğrulama doğruluğu 0,8937, standart sapma ise ±0,0302 olarak hesaplanmıştır. Standart sapmanın görece düşük kalması, modelin farklı veri bölümleri karşısında kararlı ve tutarlı bir performans sergilediğine işaret etmektedir.

Rastgele Orman modeline uygulanan SHAP TreeExplainer analizi, her bir özelliğin model çıktısına olan katkısını bireysel gözlem düzeyinde ölçerek özellik önem sıralamasını ortaya koymuştur. SHAP özet grafiği incelendiğinde belirli özelliklerin tahmin kararı üzerinde diğerlerine kıyasla çok daha belirleyici bir ağırlık taşıdığı görülmektedir. Yüksek SHAP değerine sahip özellikler, modelin onay ya da red kararına ulaşmasında birincil etken konumunda iken düşük SHAP değeri taşıyan özellikler tahmin sürecine yalnızca marjinal katkı sağlamaktadır. Bu analiz, modelin kara kutu yapısını şeffaf hale getirerek kredi uzmanlarının model kararlarını yorumlamasına ve güven duygusunu pekiştirmesine önemli bir zemin hazırlamaktadır.

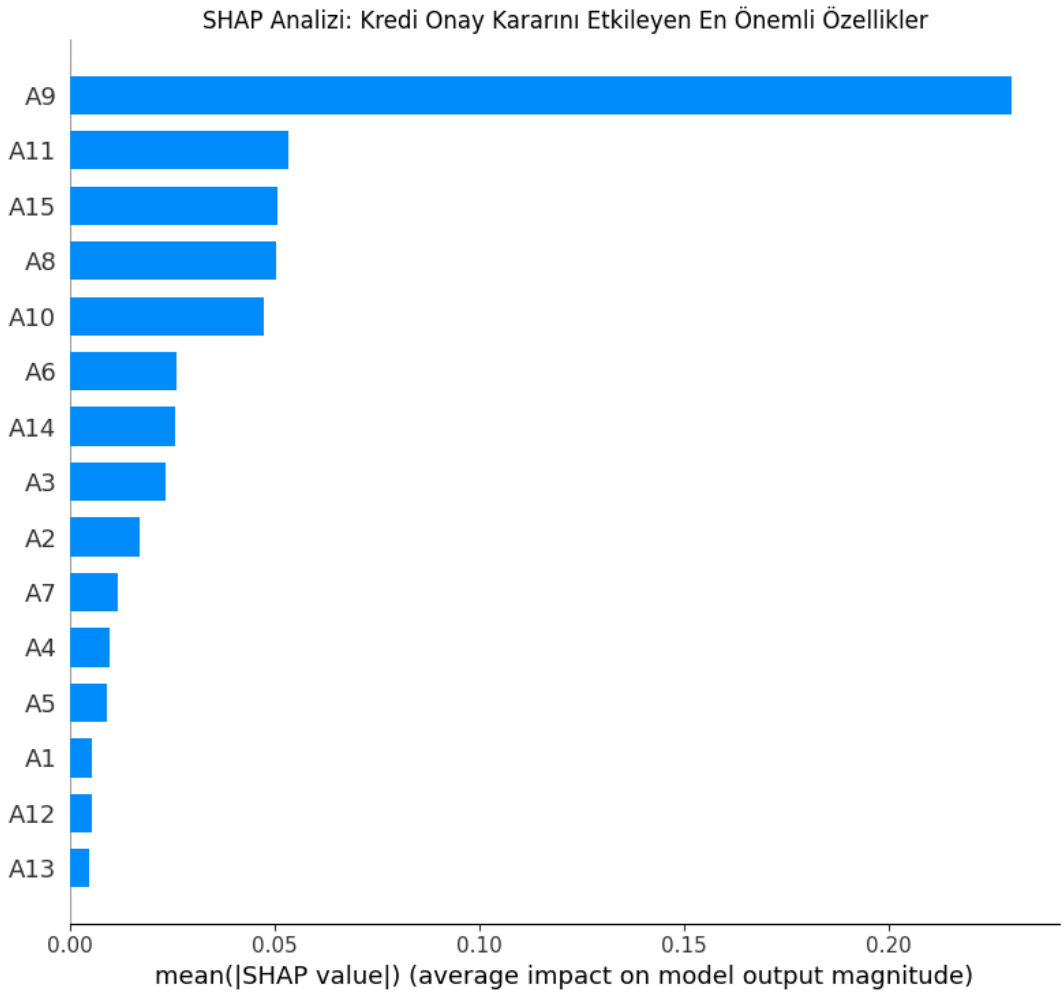

Elde edilen bulgular genel olarak değerlendirildiğinde topluluk öğrenme yöntemlerinin bireysel modellerle kıyaslandığında daha dengeli ve güvenilir bir performans profili sergilediği görülmektedir. Bu sonuç, Liu ve arkadaşlarının 2019 yılında topluluk yöntemlerinin genelleme kapasitesini artırdığına dair bulgusuyla örtüşmektedir. Rastgele Orman'ın hem doğruluk hem de ROC-AUC açısından güçlü bir performans sergilemesi, Dey'in 2016 yılındaki sistematik karşılaştırma çalışmasındaki tespitlerini doğrulamaktadır. Karar Ağacı'nın düşük performansı ise tek bir ağacın eğitim verisine aşırı uyum gösterme eğiliminin test setine genelleme yapamamasına yol açtığını açıkça ortaya koymaktadır. Yapay Sinir Ağı'nın beklentinin altında kalması, 690 gözlem gibi görece küçük bir veri setinde derin mimarilerin parametre kapasitesini tam anlamıyla kullanamadığına işaret etmekte ve Huang ile Kuo'nun 2018 yılında büyük ölçekli veri setlerinde derin öğrenmenin avantajlarını vurguladığı bulgusuyla tutarlılık göstermektedir. SMOTE uygulamasının model performansına katkısı ise Jayalakshmi ve Santhakumaran'ın 2011 yılında veri dengelemenin sınıflandırma başarısını artırdığına dair çalışmasıyla doğrudan örtüşmektedir. Optimal karar eşiğinin 0,50 yerine 0,4257 olarak belirlenmesi, kredi onay tahmini bağlamında yanlış negatif maliyetinin yanlış pozitif maliyetinden daha ağır bastığını sayısal olarak teyit etmekte ve Gültepe'nin 2019 yılında ROC-AUC ile eşik analizi kombinasyonunun model seçimindeki belirleyici rolünü vurguladığı bulgusunu desteklemektedir.

4. Sonuç ve Öneriler

Bu çalışmada UCI Credit Approval veri seti üzerinde yürütülen kapsamlı makine öğrenmesi analizi, kredi onay tahmini problemine yönelik çok boyutlu bir değerlendirme imkânı sunmuştur. Karar Ağacı, K-En Yakın Komşu, Rastgele Orman, XGBoost, LightGBM ve Yapay Sinir Ağları olmak üzere altı farklı algoritmanın karşılaştırmalı olarak incelendiği bu çalışmada, bireysel modellerin güçlü yönlerini bir araya getiren Stacking tabanlı hibrit bir mimari önerilmiş ve deneysel bulgular aracılığıyla etkinliği ortaya konulmuştur.

Elde edilen sonuçlar birkaç temel bulgu etrafında şekillenmektedir. Sınıf dengesizliğinin SMOTE yöntemiyle giderilmesi, modellerin azınlık sınıfına yönelik duyarlılığını belirgin biçimde artırmış ve salt doğruluk metriğinin yanıltıcı olabileceği dengesiz veri yapılarında daha güvenilir sonuçlar elde edilmesini sağlamıştır. Topluluk öğrenme yöntemlerinin bireysel modellerle kıyaslandığında genel olarak daha dengeli bir performans profili sergilediği görülmüş; özellikle GridSearchCV ile optimize edilen Rastgele Orman modeli yüzde 89,68 doğruluk oranıyla en yüksek noktasal başarıya ulaşmıştır. Önerilen Stacking hibrit modeli ise 0,8696 doğruluk ve 0,9034 ROC-AUC skoru ile bireysel

modellerin büyük çoğunluğunu geride bırakmış; 10 katlı çapraz doğrulamada elde edilen 0,8937 ortalama doğruluk ve ±0,0302 standart sapma değerleri modelin farklı veri bölümlerine karşı kararlı ve güvenilir bir yapı sergilediğini kanıtlamıştır. Finansal risk yönetimi açısından kritik bir bulgu olarak optimal karar eşiğinin standart 0,50 değerinin altında, 0,4257 düzeyinde belirlenmesi, modelin onay sınıfına yönelik duyarlılığı ön planda tuttuğunu ve gerçek dünya uygulamalarında yanlış negatif maliyetini minimize etmeye yönelik bir yapı kurduğunu ortaya koymuştur. SHAP analizi ise modelin kara kutu niteliğini aşarak hangi özelliklerin kredi kararını ne ölçüde etkilediğini şeffaf biçimde ortaya koymuş ve açıklanabilir yapay zeka yaklaşımlarının finansal karar destek sistemlerindeki potansiyelini somut olarak göstermiştir.

Gelecekteki çalışmalar için birçok verimli araştırma yönü öngörülmektedir. Öncelikle bu çalışmada kullanılan 690 gözlemlik veri setinin görece sınırlı büyüklüğü, özellikle Yapay Sinir Ağları gibi parametre yoğun modellerin kapasitesini tam anlamıyla kullanmasını kısıtlamaktadır; bu nedenle daha büyük ve gerçek zamanlı finansal veri setleri üzerinde benzer analizlerin tekrarlanması hem modellerin genelleme gücünü artıracak hem de bulgular arasındaki karşılaştırmalı geçerliliği güçlendirecektir. Hiperparametre optimizasyonu açısından bu çalışmada yalnızca Rastgele Orman modeline uygulanan GridSearchCV yaklaşımının tüm modellere genişletilmesi ve hesaplama açısından daha verimli olan Bayesian optimizasyon ya da Optuna gibi araçlarla desteklenmesi, her modelin gerçek performans tavanına ulaşılmasını sağlayabilir. Derin öğrenme mimarileri bağlamında ise LSTM ve Transformer tabanlı modellerin özellikle zaman serisi niteliği taşıyan finansal verilerle entegre edilmesi, kredi risk tahmininde yeni bir performans eşiği oluşturabilir. Özellik mühendisliği alanında A1–A15 olarak anonim tutulan değişkenlerin gerçek finansal karşılıkları bilindiğinde etki analizi ile elde edilecek alan bilgisine dayalı yeni özellikler türetilmesi model yorumlanabilirliğini ve tahmin gücünü eş zamanlı olarak artırabilir. Son olarak bu çalışmada geliştirilen Stacking mimarisinin bir web servisi ya da API aracılığıyla gerçek zamanlı kredi değerlendirme sistemlerine entegre edilmesi ve SHAP tabanlı açıklanabilirlik katmanının kullanıcı arayüzüyle birleştirilmesi, araştırmanın akademik katkısını somut bir endüstriyel uygulamaya dönüştürme açısından en öncelikli gelecek adımı olarak değerlendirilmektedir.

KAYNAKÇA

1. Tong, K., Han, Z., Shen, Y., Long, Y. ve Wei, Y. (2024). An Integrated Machine Learning and Deep Learning Framework for Credit Card Approval Prediction. *arXiv preprint*, arXiv:2409.16676.

2. Shreya ve Pathak, H. (2025). Explainable Artificial Intelligence Credit Risk Assessment using Machine Learning. *arXiv preprint*, arXiv:2506.19383.

3. Gunnarsson, B. R., Vanden Broucke, S., Baesens, B., Óskarsdóttir, M. ve Lemahieu, W. (2021). Deep Learning for Credit Scoring: Do or Don't? *European Journal of Operational Research*, 295(1), 292–305.

4. Gramegna, A. ve Giudici, P. (2021). SHAP and LIME: An Evaluation of Discriminative Power in Credit Risk. *Frontiers in Artificial Intelligence*, 4, 140.

5. Chen, Y., Calabrese, R. ve Martin-Barragan, B. (2024). Interpretable Machine Learning for Unbalanced Credit Scoring Datasets. *European Journal of Operational Research*, 312(1), 357–372.

6. Brown, I. ve Mues, C. (2012). An Experimental Comparison of Classification Algorithms for Imbalanced Credit Scoring Data Sets. *Expert Systems with Applications*, 39(3), 3446–3453.

7. Dumitrescu, E., Hué, S., Hurlin, C. ve Tokpavi, S. (2022). Machine Learning for Credit Scoring: Improving Logistic Regression with Non-Linear Decision-Tree Effects. *European Journal of Operational Research*, 297(3), 1178–1192.

8. Li, Y., Zhao, R. ve Sha, M. (2024). A Hybrid Credit Risk Evaluation Model Based on Three-Way Decisions and Stacking Ensemble Approach. *Computational Economics*, 1–24.

9. Aruleba, I. ve Sun, Y. (2024). Effective Credit Risk Prediction Using Ensemble Classifiers with Model Explanation. *IEEE Access*.

10. Barbaglia, L., Manzan, S. ve Tosetti, E. (2023). Forecasting Loan Default in Europe with Machine Learning. *Journal of Financial Econometrics*, 21(2), 569–596.

11. Thomas, L., Crook, J. ve Edelman, D. (2017). *Credit Scoring and Its Applications*. SIAM.